Procesos ETL

Tema 6: Limpieza, transformación y normalización de datos. Parte I Expresiones regulares

Adquisición y preparación de datos

Universitat d'Alacant
Universidad de Alicante

Ciclo de vida del proyecto IA

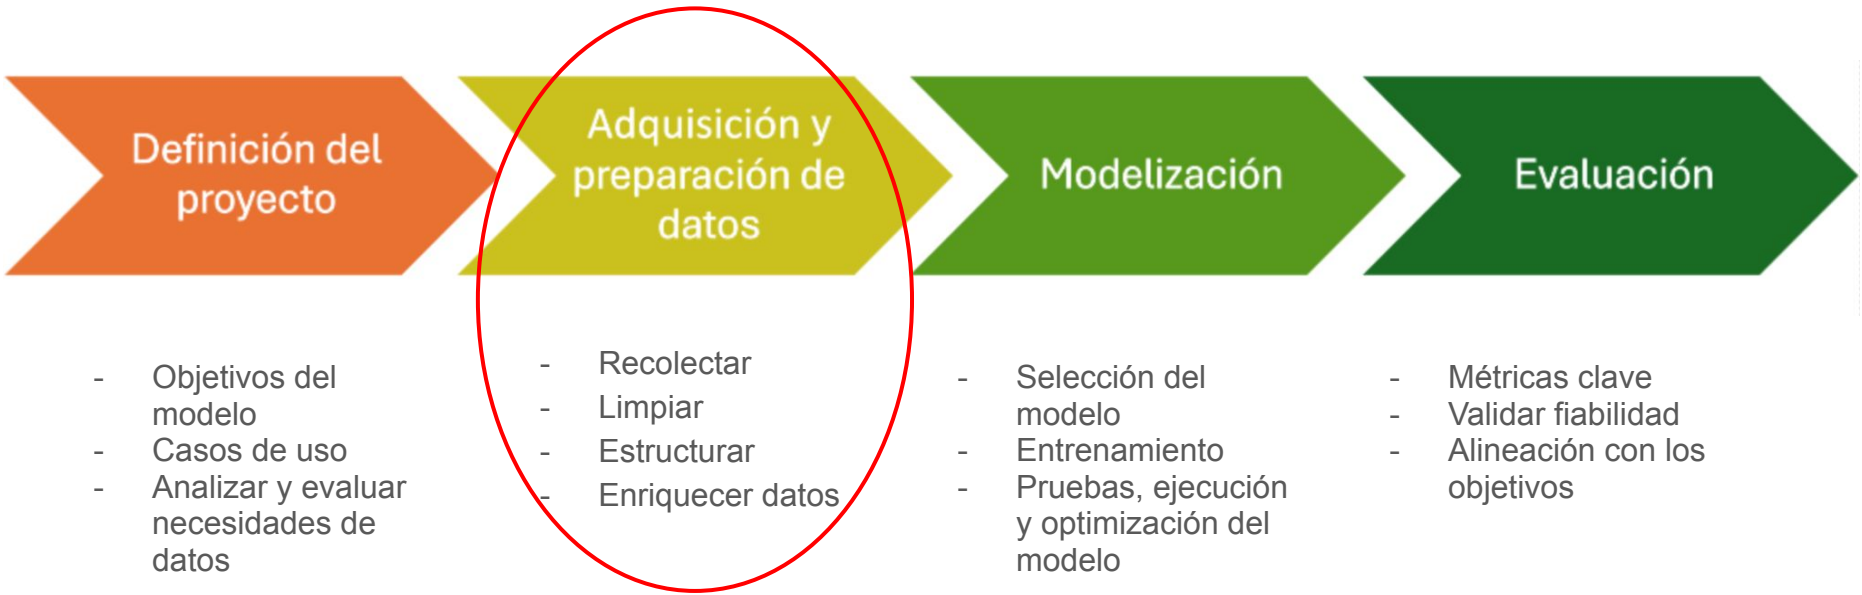

Preparación de datos

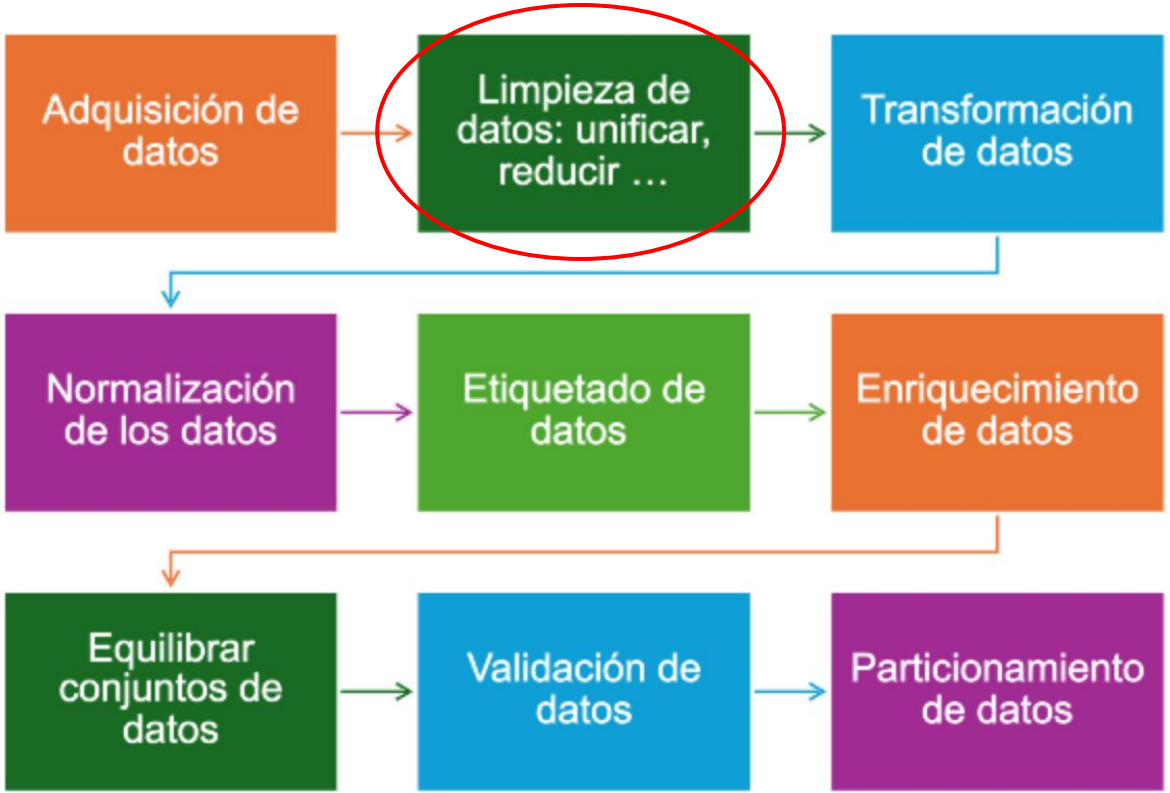

Qué es un proceso ETL

Extract

- **Extraer** datos desde las distintas fuentes de origen - fusión de datos
  - Identificar fuentes
  - Identificar conjunto de datos
  - Conectores para la adquisición
  - Fuentes como Hadoop, datos abiertos, Sql, Nosql (MongoDB, Cassandra), repositorios RDF, Wikidata, etc
- **Analizar** los datos obtenidos
  - Tipos de datos
  - Codificación origen
  - Semántica
- **Interpretar** y comprobar que cumplen con la estructura esperada

Qué es un proceso ETL

Transform

Depurar y ajustar a los requisitos, aplicando **reglas** que guíen las transformaciones de los datos para un formato final, contenido y forma

- Selección de datos (columnas, filas…), eliminado ruido
- Modificación del contenido o la estructura de los datos
- Integración con datos de otras fuentes
- Corrección de errores
- Cálculo de valores derivados o agregados a partir de datos procesados
- Traducción de valores
- Codificación
- Tratamiento de textos
- Validación de datos frente a reglas de calidad

Qué es un proceso ETL

Load

Carga y actualización de los datos en el almacén de datos

- Selección sistema destino: fichero, *data warehouse*, BD relacional, índice, NoSql, etc
- Nuevo o sobrescribir (ejemplo BD, Excel)
- Historial de cambios

Tipos de proceso de carga:

- **Acumulación simple**
- **Rolling** para mayor granularidad

Limpieza de datos

Limpieza de datos

Los datos sin procesar suelen ser imperfectos, contienen errores, faltan valores o están duplicados.

Objetivo de la limpieza de datos es **eliminar** estas **anomalías para garantizar la calidad y su fiabilidad**.

Una limpieza adecuada ayuda a evitar que los datos defectuosos afecten al rendimiento del modelo.

- Corregir **errores**
- Eliminar **duplicados**
- Gestionar valores que **faltan**: reemplazo, interpolación o eliminación
- Gestionar valores **atípicos**
- **Unificar** de tipos de datos
- Aplicar la **reducción** de datos
    - La reducción de datos filtra los campos que no son necesarios
    - Eliminar los valores que se encuentran fuera del rango esperado
    - Redundancia, conservar datos redundantes puede ralentizar el análisis y consumir recursos

Limpieza de datos

Limpieza de datos mediante:

1. Expresiones regulares
    - Introducción
    - Sintaxis
    - Ejemplos

2. Otros mecanismos para la limpieza de datos

Expresiones regulares

Expresiones regulares

Mecanismo **eficiente y flexible** que facilita el procesamiento de datos.

Secuencia de caracteres que forman un patrón que facilitan **filtrar, encontrar, validar y tratar** un texto.

Sus principales componentes:

- **Literales**: caracteres que conforman cualquier palabra
- **Clases** de caracteres: son definidas a través de una lista de caracteres entre corchetes
- **Metacaracteres**: elemento especial que permiten delimitar, iterar, alternar a los literales.

Expresiones regulares

Regular Expressions Cheat Sheet by Dave Child (DaveChild) via cheatography.com/1/cs/5/

https://cheatography.com/davechild/cheat-sheets/regular-expressions/pdf/

Cheatography

Regular Expressions Cheat Sheet
by Dave Child (DaveChild) via cheatography.com/1/cs/5/

Anchors

^	Start of string, or start of line in multi-line pattern
\A	Start of string
$	End of string, or end of line in multi-line pattern
\Z	End of string
\b	Word boundary
\B	Not word boundary
\<	Start of word
\>	End of word

Character Classes

\c	Control character
\s	White space
\S	Not white space
\d	Digit
\D	Not digit
\w	Word
\W	Not word
\x	Hexadecimal digit
\O	Octal digit

POSIX

[:upper:]	Upper case letters
[:lower:]	Lower case letters
[:alpha:]	All letters
[:alnum:]	Digits and letters
[:digit:]	Digits
[:xdigit:]	Hexadecimal digits
[:punct:]	Punctuation
[:blank:]	Space and tab
[:space:]	Blank characters
[:cntrl:]	Control characters
[:graph:]	Printed characters
[:print:]	Printed characters and spaces
[:word:]	Digits, letters and underscore

Assertions

?=	Lookahead assertion
?!	Negative lookahead
?<=	Lookbehind assertion
?!= or ?<!	Negative lookbehind
?>	Once-only Subexpression
?()	Condition [if then]
?()|	Condition [if then else]
?#	Comment

Quantifiers

*	0 or more	{3}	Exactly 3
+	1 or more	{3,}	3 or more
?	0 or 1	{3,5}	3, 4 or 5

Add a ? to a quantifier to make it ungreedy.

Escape Sequences

\	Escape following character
\Q	Begin literal sequence
\E	End literal sequence

"Escaping" is a way of treating characters which have a special meaning in regular expressions literally, rather than as special characters.

Common Metacharacters

^	[	.	$
{	*	(	\
+	)	|	?
<	>		

The escape character is usually \

Special Characters

\n	New line
\r	Carriage return
\t	Tab
\v	Vertical tab
\f	Form feed
\xxx	Octal character xxx
\xhh	Hex character hh

Groups and Ranges

.	Any character except new line (\n)
(a|b)	a or b
(...)	Group
(?:...)	Passive (non-capturing) group
[abc]	Range (a or b or c)
[^abc]	Not (a or b or c)
[a-q]	Lower case letter from a to q
[A-Q]	Upper case letter from A to Q
[0-7]	Digit from 0 to 7
\x	Group/subpattern number "x"

Ranges are inclusive.

Pattern Modifiers

g	Global match
i *	Case-insensitive
m *	Multiple lines
s *	Treat string as single line
x *	Allow comments and whitespace in pattern
e *	Evaluate replacement
U *	Ungreedy pattern

* PCRE modifier

String Replacement

$n	nth non-passive group
$2	"xyz" in /^(abc(xyz))$/
$1	"xyz" in /^(?:abc)(xyz)$/
$`	Before matched string
$'	After matched string
$+	Last matched string
$&	Entire matched string

Some regex implementations use \ instead of $.

By **Dave Child** (DaveChild)
cheatography.com/davechild/
www.addedbytes.com

Published 19th October, 2011.
Last updated 2nd January, 2015.
Page 1 of 1.

Expresiones regulares

Consultar RegExLib.com Regular Expression Cheat Sheet

regexlib.com/CheatSheet.aspx

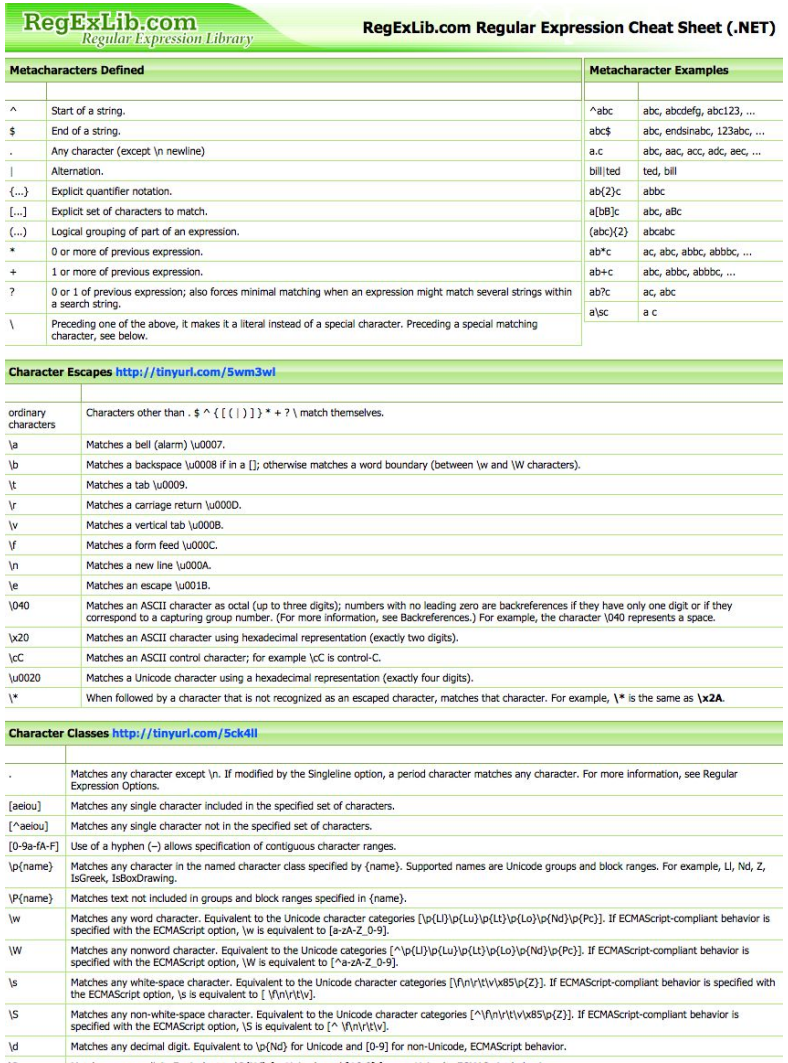

RegExLib.com
Regular Expression Library

RegExLib.com Regular Expression Cheat Sheet (.NET)

Metacharacters Defined		Metacharacter Examples	
^	Start of a string.	^abc	abc, abcdefg, abc123, ...
$	End of a string.	abc$	abc, endsinabc, 123abc, ...
.	Any character (except \n newline)	a.c	abc, aac, acc, adc, aec, ...
|	Alternation.	bill|ted	ted, bill
{...}	Explicit quantifier notation.	ab{2}c	abbc
[...]	Explicit set of characters to match.	a[bB]c	abc, aBc
(...)	Logical grouping of part of an expression.	(abc){2}	abcabc
*	0 or more of previous expression.	ab*c	ac, abc, abbc, abbbc, ...
+	1 or more of previous expression.	ab+c	abc, abbc, abbbc, ...
?	0 or 1 of previous expression; also forces minimal matching when an expression might match several strings within a search string.	ab?c	ac, abc
\	Preceding one of the above, it makes it a literal instead of a special character. Preceding a special matching character, see below.	a\sc	a c

Character Escapes http://tinyurl.com/5wm3wl	
ordinary characters	Characters other than . $ ^ { [(|)] } * + ? \ match themselves.
\a	Matches a bell (alarm) \u0007.
\b	Matches a backspace \u0008 if in a []; otherwise matches a word boundary (between \w and \W characters).
\t	Matches a tab \u0009.
\r	Matches a carriage return \u000D.
\v	Matches a vertical tab \u000B.
\f	Matches a form feed \u000C.
\n	Matches a new line \u000A.
\e	Matches an escape \u001B.
\040	Matches an ASCII character as octal (up to three digits); numbers with no leading zero are backreferences if they have only one digit or if they correspond to a capturing group number. (For more information, see Backreferences.) For example, the character \040 represents a space.
\x20	Matches an ASCII character using hexadecimal representation (exactly two digits).
\cC	Matches an ASCII control character; for example \cC is control-C.
\u0020	Matches a Unicode character using a hexadecimal representation (exactly four digits).
*	When followed by a character that is not recognized as an escaped character, matches that character. For example, ***** is the same as **\x2A**.

Character Classes http://tinyurl.com/5ck4ll	
.	Matches any character except \n. If modified by the Singleline option, a period character matches any character. For more information, see Regular Expression Options.
[aeiou]	Matches any single character included in the specified set of characters.
[^aeiou]	Matches any single character not in the specified set of characters.
[0-9a-fA-F]	Use of a hyphen (–) allows specification of contiguous character ranges.
\p{name}	Matches any character in the named character class specified by {name}. Supported names are Unicode groups and block ranges. For example, Ll, Nd, Z, IsGreek, IsBoxDrawing.
\P{name}	Matches text not included in groups and block ranges specified in {name}.
\w	Matches any word character. Equivalent to the Unicode character categories [\p{Ll}\p{Lu}\p{Lt}\p{Lo}\p{Nd}\p{Pc}]. If ECMAScript-compliant behavior is specified with the ECMAScript option, \w is equivalent to [a-zA-Z_0-9].
\W	Matches any nonword character. Equivalent to the Unicode categories [^\p{Ll}\p{Lu}\p{Lt}\p{Lo}\p{Nd}\p{Pc}]. If ECMAScript-compliant behavior is specified with the ECMAScript option, \W is equivalent to [^a-zA-Z_0-9].
\s	Matches any white-space character. Equivalent to the Unicode character categories [\f\n\r\t\v\x85\p{Z}]. If ECMAScript-compliant behavior is specified with the ECMAScript option, \s is equivalent to [\f\n\r\t\v].
\S	Matches any non-white-space character. Equivalent to the Unicode character categories [^\f\n\r\t\v\x85\p{Z}]. If ECMAScript-compliant behavior is specified with the ECMAScript option, \S is equivalent to [^ \f\n\r\t\v].
\d	Matches any decimal digit. Equivalent to \p{Nd} for Unicode and [0-9] for non-Unicode, ECMAScript behavior.

Expresiones regulares

Algunos de los más utilizados *metacharacters*:

- **** Indica que el siguiente carácter es especial y se desea tratar como un literal
- **^** Indica el principio de una cadena
- **$** Indica el final de una cadena
- **.** Cualquier carácter salvo el salto de línea (\n)
- **(...)** Agrupación lógica de partes de una expresión.
- **[...]** Un conjunto de caracteres de la expresión
  - [xyz] Indica coincidencia con cualquiera de los caracteres entre corchetes
  - [^xyz] cualquiera carácter que no esté entre corchetes
  - [a-z] cualquier carácter dentro del rango especificado
  - [0-9a-fA-F] cualquier carácter dentro de los rangos especificados
- **{...}** Indica un número o intervalo de longitud de la expresión
  - {n} repetición de un carácter n veces.
  - {n,} repetición de un carácter como mínimo n veces
  - {n,m} repetición de un carácter como mínimo n veces y máximo m veces
- **?** 0-1 ocurrencias de la expresión
- **+** 1-n ocurrencias de la expresión
- ***** 0-n ocurrencias de la expresión
- | Para indicar una disyunción lógica, elegir entre dos valores x|y se tiene que cumplir al menos uno de los dos

Expresiones regulares

Algunos de los más utilizados *character classes*:

- **\w** Coincide con cualquier carácter alfanumérico o _, equivale a [a-zA-Z_0-9]
- **\W** Coincide con cualquier carácter no alfanumérico ni _, equivale a [^a-zA-Z_0-9]
- **\s** Espacio en blanco, ECMAScript equivale a [\f\n\r\t\v]
- **\S** No espacio en blanco, ECMAScript equivale a [^ \f\n\r\t\v]
- **\d** Dígito decimal, equivale a [0-9]
- **\D** No dígito decimal, equivale a [^0-9]
- **\x** Dígito hexadecimal
- **\p**{name} Coincide con cualquier carácter de la clase o categoría Unicode especificada por {name}.
- **\P**{name} Coincide con el texto no incluido en los grupos y rangos de bloques especificados en {name}

Anchors:

- **\b** Límite de palabra
- **\B** No límite de palabra

Expresiones regulares

Flags, modifican el comportamiento del patrón

- **g** encuentra todas las coincidencias, si no se usa solo devuelve la primera coincidencia
- **i** no distingue entre mayúsculas y minúsculas
- **m** Para múltiples líneas
- **s** Habilita el modo “dotall”, un punto “.” coincide con el carácter de línea nueva \n tratando a la cadena como una única línea
- **y** búsqueda en la posición exacta del texto
- **u** Permite el soporte completo de Unicode

Expresiones regulares

PDI incluye pasos para el uso de expresiones regulares.

Facilita la inclusión de scripts en Javascript para la limpieza de datos y otras tareas.

En JavaScript se pueden utilizar los métodos `exec()` y `test()` de `RegExp`, y `match()`, `matchAll()`, `replace()`, `replaceAll()`, `search()` y `split()` de `String`.

```
str = "Impreso en casa de Monreal núm. 2, 1902";
const regex = /\d+$/;
console.log(regex.test(str)); // true

console.log(regex.exec(str));
```

```
[
  '1902',
  index: 35,
  input: 'Impreso en casa de Monreal núm. 2, 1902',
  groups: undefined
]
```

```
const regex2 = /\d+/g;
const result = Array.from(str.matchAll(regex2), (m) => m[0]);

console.log(result);
```

```
[ '2', '1902' ]
```

https://developer.mozilla.org/en-US/docs/Web/JavaScript/Reference/Regular_expressions

Expresiones regulares

^ $ Inicio o final de un string (*anchors*)

- ^(.+:) o bien ^(Auxiliar localización):?( )?

```
s = "Auxiliar localización: Parque Natural de Redes, Asturias";
const pRE = /^(Auxiliar localización):?( )?.*/;
pRE.test(s);
```

- (.*)(\d+)$ cadena que termine en número

```
s = "Auxiliar localización: Parque Natural de Redes, Asturias, 1968";
const pRE = /.*\d+$/;
pRE.test(s);
```

- Ambos se puede usar juntos para comprobar si una cadena coincide completamente con el patrón

```
s = "09:37";
const pRE = /^\d\d:\d\d$/;
pRE.test(s);
```

Expresiones regulares

- **\b** Búsqueda de palabras completas

```
s1 = "Edición digital a partir de Obras completas de Baltasar Gracián. Vol II";
s2 = "Ed. Emilio Blanco sin Volumen definido. 1993";

const pRE = /\bVol\b/;
pRE.test(s1);
pRE.test(s2);

console.log(s1.replace(pRE, 'Volumen'));
console.log(s2.replace(pRE, 'Volumen'));

const pRE2 = /Vol/;
pRE2.test(s1);
pRE2.test(s2);

console.log(s1.replace(pRE2, 'Volumen'));
console.log(s2.replace(pRE2, 'Volumen'));
```

Expresiones regulares

- \ Indica que el siguiente carácter es especial y se desea tratar como un literal
  - Para escapar caracteres especiales [\ ^ $. | ? * + ( )
  - Se debe escapar / si se usa el patrón /.../ (pero no dentro de new RegExp).
  - Si se usa new RegExp, se deben duplicar las barras invertidas \\, porque las comillas de cadena consumen una.

```
s1 = "Edición digital a partir de Obras completas de Baltasar Gracián. Volumen II";
s2 = "Ed. Emilio Blanco sin Volumen, (Murcia)";

const pRE = /\./;
pRE.test(s1);

const pRE2 = /(.*, )?\(?(.+)\)?$/;
pRE2.test(s1);
pRE2.test(s2);
```

Expresiones regulares

- () Para agrupar

```
s1 = "Auxiliar localización: Sanlúcar de Barrameda, Cádiz";
s2 = "Ed. Emilio Blanco sin Volumen, (Murcia)";

const pRE = /(.*, )?\(?(.+)\)?$/;
pRE.test(s1); // → true grupo2 = Cádiz
pRE.test(s2); // → true grupo2 = Murcia
```

Expresiones regulares

- **[...]** Un conjunto de caracteres de la expresión
  - [xyz] Indica coincidencia con cualquiera de los caracteres entre corchetes
  - [^xyz] cualquiera caracter que no esté entre corchetes
  - [a-z] cualquier caracter dentro del rango especificado
  - [0-9a-fA-F] cualquier caracter dentro de los rangos especificados

```
//Obtener todas las obras cuya reproducción indique un volumen. Existen diferentes formas de indicarlo

s1 = "Edición digital a partir de Obras completas de Baltasar Gracián. Volumen II";
s2 = "Ed. Emilio Blanco volumen I, pp23, (Murcia)";
s3 = "Ed. Emilio Blanco Vol.2 (Murcia)";


const pRE = /[Vv]olumen/;
pRE.test(s1);
pRE.test(s2);
pRE.test(s3);
```

```
const pRE2 = /[Vv]ol(\.|umen)/;
pRE2.test(s1));
pRE2.test(s2));
pRE2.test(s3));
```

Expresiones regulares

```
//Obtener todas las obras cuya reproducción indique un volumen. Existen diferentes formas de indicarlo

s1 = "Edición digital a partir de Obras completas de Baltasar Gracián. Volumen II";
s2 = "Ed. Emilio Blanco volumen I, pp23, (Murcia)";
s3 = "Ed. Emilio Blanco Vol.2 (Murcia)";


 const pRE = /[Vv]olumen/;                          const pRE2 = /[Vv]ol(\.|umen)/;
 pRE.test(s1);                                      console.log(pRE2.test(s1));
 pRE.test(s2);                                      console.log(pRE2.test(s2));
 pRE.test(s3);                                      console.log(pRE2.test(s3));
```

¿Alguna otra expresión regular que podamos usar?

Expresiones regulares

```
//Obtener todas las obras cuya reproducción indique un volumen. Existen diferentes formas de indicarlo

s1 = "Edición digital a partir de Obras completas de Baltasar Gracián. Volumen II";
s2 = "Ed. Emilio Blanco volumen I, pp23, (Murcia)";
s3 = "Ed. Emilio Blanco Vol.2 (Murcia)";


 const pRE = /[Vv]olumen/;
 pRE.test(s1); // → true
 pRE.test(s2); // → true
 pRE.test(s3); // → false
```

```
const pRE2 = /[Vv]ol(\.|umen)/;
pRE2.test(s1); // → true
pRE2.test(s2); // → true
pRE2.test(s3); // → true
```

/\bVol(\.|umen)?\b/**i**

Expresiones regulares

- **[...]** Un conjunto de caracteres de la expresión

Las clases de caracteres son abreviaturas para ciertos conjuntos de caracteres:

\d →[0-9]
\w →[a-zA-Z0-9_]
\s →[\t\n\v\f\r], además de otros caracteres de espacio de unicode.

Expresiones regulares

Ejercicio 1 - Obtener expresión regular para comprobar que una fecha del siglo 21 es correcta en formato YYYY-MM-DD

```
s1 = "[Vicente Barberá Masip o Enrique Desfilis Barberá]., 1898";
s2 = "Imp. Vda. de Ayoldi, 1883-06-24";
s3 = "Direcció General del Llibre, Arxius i Biblioteques, 2022-12-31";


const pRE = /…/;


console.log(pRE.test(s1));
console.log(pRE.test(s2));
console.log(pRE.test(s3));
```

Expresiones regulares

Ejercicio 1 - Obtener expresión regular para comprobar que una fecha del siglo 21 es correcta en formato YYYY-MM-DD

```
s1 = "[Vicente Barberá Masip o Enrique Desfilis Barberá]., 1898";
s2 = "Imp. Vda. de Ayoldi, 1883-06-24";
s3 = "Direcció General del Llibre, Arxius i Biblioteques, 2022-12-31";


const pRE = /(20\d{2}|2100)-(0[1-9]|1[0-2])-(0[1-9]|[12]\d|3[01])/;
console.log(pRE.test(s1)); // → false
console.log(pRE.test(s2)); // → false
console.log(pRE.test(s3)); // → true


// (20(1\d|2[0-5]) -> Años del 2000 al 2025.
// (0[1-9]|1[0-2]) -> Grupo de captura el mes (01-12)
// (0[1-9]|[12]\d|3[01]) -> Grupo de captura para el día (01-31)
```

Expresiones regulares

- . Cualquier carácter salvo el salto de línea
- + 1-n ocurrencias de la expresión
- * 0-n ocurrencias de la expresión
- ? 0-1 ocurrencias de la expresión

```
s1 = "Auxiliar localización: Sanlúcar de Barrameda, Cádiz";
s2 = "Ed. Emilio Blanco sin Volumen, (Murcia)";
s3="";

pRE = /.*/;
console.log(pRE.test(s1)); // → true
console.log(pRE.test(s3)); // → ?

pRE = /.+/;
console.log(pRE.test(s3)); // → ?

pRE = /(.*, )?\(?(.+)\)?$/;
pRE.test(s1); // → ?
pRE.test(s2); // → ?
```

Expresiones regulares

- **{...}** Indica un número o intervalo de longitud de la expresión
  - {n} repetición de un carácter n veces.
  - {n,} repetición de un carácter como mínimo n veces
  - {n,m} repetición de un carácter como mínimo n veces y máximo m veces

```
codigos = "CP: 28001, 03001, 123456.";
console.log(codigos.match(/\b\d{5}\b/g));

//Extrae número de registro variable
idReg = "ID123, ID4567, ID7450123.";
validados = idReg.match(/\d{4,6}/g);
```

Expresiones regulares

Ejercicio 2 - Validar una contraseña mediante una expresión regular. La contraseña debe tener entre 8 y 16 caracteres, contener al menos una letra minúscula, una mayúscula y un número.

Expresiones regulares

Ejercicio 2 - Validar una contraseña mediante una expresión regular. La contraseña debe tener entre 8 y 16 caracteres y contener al menos una letra minúscula, una mayúscula y un número.

```
/**
 * Validar contraseña con una expresión regular.
 * @param {string}
 * @returns {boolean} true si es válida y false si no lo es
 */
function isValid(pass) {
  const regex = /^(?=.*[a-z])(?=.*[A-Z])(?=.*\d).{8,16}$/;
  return regex.test(pass);
}


console.log(isValid("P@ss11111!"));
console.log(isValid("NoSeQue_poner3"));
console.log(isValid("1234567EsoEs"));
console.log(isValid("1234"));
```

Expresiones regulares

Ejercicio 3 - ¿Cómo limpiamos dos o más espacios en blanco en la siguiente cadena de texto?

Es el título original de una obra publicada en la BVMC, tal cual se puede leer a continuación:

Recopilacion verificada por Felipe Mateu, de las noticias y reglas por las que se gobierna la Real Acequia de Moncada (Valencia), efectuada por acuerdo de su Junta de cequeiros en 10 de octubre de 1757 : Concluida esta recopilación en 16 de julio de 1758

Expresiones regulares

Ejercicio 3:

```
s1 = "Recopilacion verificada por Felipe Mateu, de las noticias y reglas por las que se gobierna la
Real Acequia de Moncada (Valencia), efectuada por acuerdo de su Junta de cequeiros en 10 de octubre de
1757  : Concluida esta recopilación en 16 de julio de 1758";

const pRE = /( ){2,}/;
const pRE2 = /\s{2,}/;
const pRE3 = /\s+/g;
const pRE4 = /\s{2,}/g;

console.log(pRE.test(s1));
console.log(pRE2.test(s1));
console.log(pRE3.test(s1));
console.log(pRE4.test(s1));

let s1SinEspaciosMultiples = s1.replace(/\s+/g, ' ');

console.log(pRE4.test(s1SinEspaciosMultiples));
```

Expresiones regulares

Ejercicio 3:

```
s1 = "Recopilacion verificada por Felipe Mateu, de las noticias y reglas por las que se gobierna la
Real Acequia de Moncada (Valencia), efectuada por acuerdo de su Junta de cequeiros en 10 de octubre de
1757  : Concluida esta recopilación en 16 de julio de 1758";

const pRE = /( ){2,}/; //encuentra al menos dos espacios en blanco seguidos
const pRE2 = /\s{2,}/; //encuentra al menos dos espacios en blanco seguidos
const pRE3 = /\s+/g; //encuentra espacios en blanco lo aplica en global
const pRE4 = /\s{2,}/g;  //encuentra al menos dos espacios en blanco seguidos lo aplica en global

console.log(pRE.test(s1)); // → true
console.log(pRE2.test(s1)); // → true
console.log(pRE3.test(s1)); // → true
console.log(pRE4.test(s1)); // → true

// método replace() con la expresión regular
let s1SinEspaciosMultiples = s1.replace(/\s+/g, ' ');
console.log(s1SinEspaciosMultiples);

console.log(pRE4.test(s1SinEspaciosMultiples)); //false
```

Expresiones regulares en PDI

Ejemplos de uso en Pentaho Data Integration

- Reemplazar partes en una cadena de texto ***replace string***
- Obtener datos de un texto mediante **regex evaluation**
- Expresiones regulares **REGEX** en MySql
- **JavaScript**

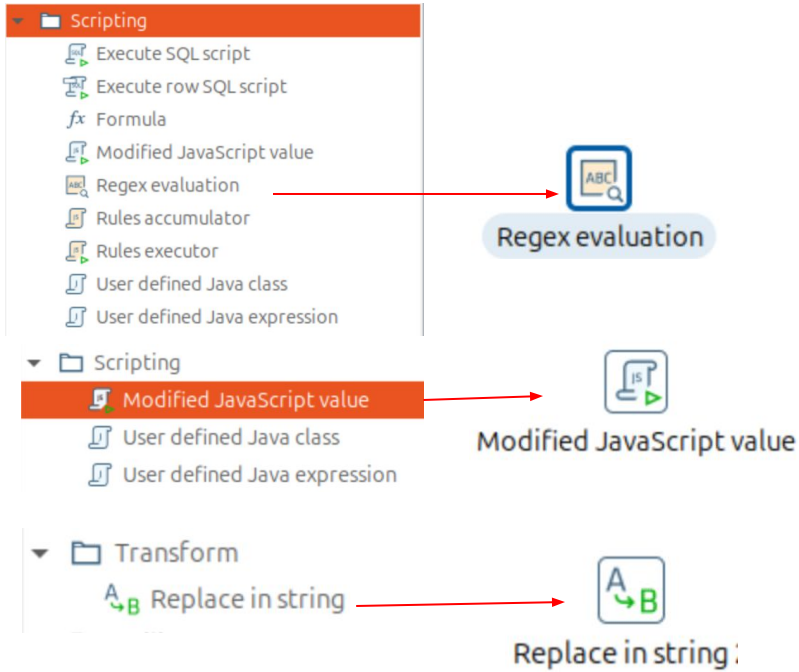

Expresiones regulares en PDI

Replace string

Se debe limpiar los campos de unos registros bibliográficos obtenidos de una fuente externa.

Después de analizar una muestra, se determina que es necesario adecuar a la norma de catalogación y forma de descripción correcta para el almacén de datos final.

Para ello se solicita realizar un proceso ETL para dicha tarea.

mencionPublicacion
"Cuadernos Hispanoamericanos", núm. 91-92 (julio-agosto 1957), pp. 180-201
"Cuadernos Hispanoamericanos", núm. 45 (septiembre 1953), pp. 279-291
"Cuadernos Hispanoamericanos", núm. 22 (julio-agosto 1951), pp. 15-19
"Cuadernos Hispanoamericanos", núm. 26 (febrero 1952)
"Cuadernos Hispanoamericanos", núm. 20 (marzo-abril 1951), pp. 169-185
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 237-238
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 241-242
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 243-286
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 289-299
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 301-306
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 323-332
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 335-381
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 383-397
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 399-414
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 415-417
"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 421-426

Expresiones regulares en PDI

Replace string

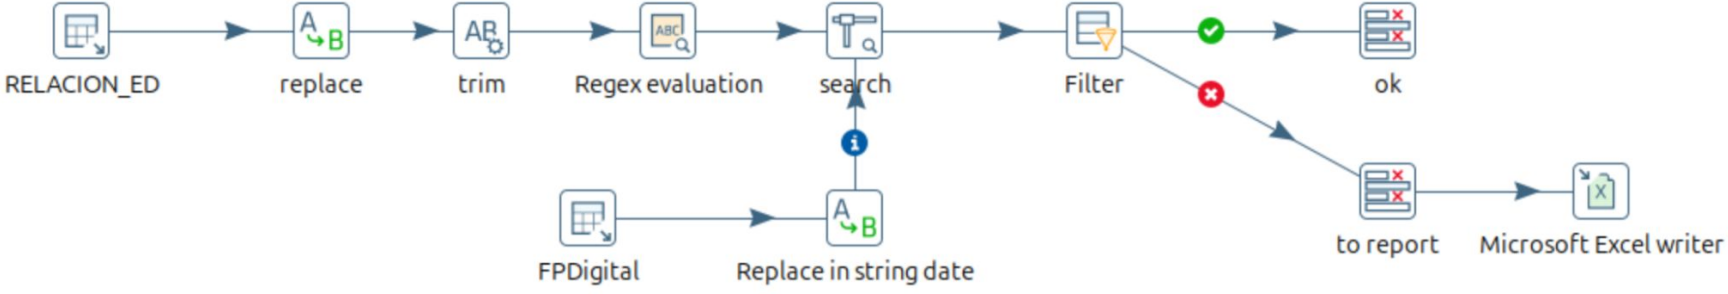

757355	"Cuadernos Hispanoamericanos", núm. 91-92 julio-agosto 1957	"Cuadernos Hispanoamericanos", núm. 91-92 (julio-agosto 1957), pp. 180-201
782746	"Cuadernos Hispanoamericanos", núm. 45 septiembre 1953	"Cuadernos Hispanoamericanos", núm. 45 (septiembre 1953), pp. 279-291
970729	"Cuadernos Hispanoamericanos", núm. 22 julio-agosto 1951	"Cuadernos Hispanoamericanos", núm. 22 (julio-agosto 1951), pp. 15-19
972802	"Cuadernos Hispanoamericanos", núm. 26 febrero 1952	"Cuadernos Hispanoamericanos", núm. 26 (febrero 1952)
975986	"Cuadernos Hispanoamericanos", núm. 20 marzo-abril 1951	"Cuadernos Hispanoamericanos", núm. 20 (marzo-abril 1951), pp. 169-185
984341	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 237-238
984389	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 241-242
984392	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 243-286
984397	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 289-299
984401	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 301-306
984407	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 323-332
984413	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 335-381
984449	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 383-397
984452	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 399-414
984455	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 415-417
984461	"Cuadernos Hispanoamericanos", núm. 11-12 septiembre-diciembre 1949	"Cuadernos Hispanoamericanos", núm. 11-12 (septiembre-diciembre 1949), pp. 421-426

Expresiones regulares en PDI

Replace string

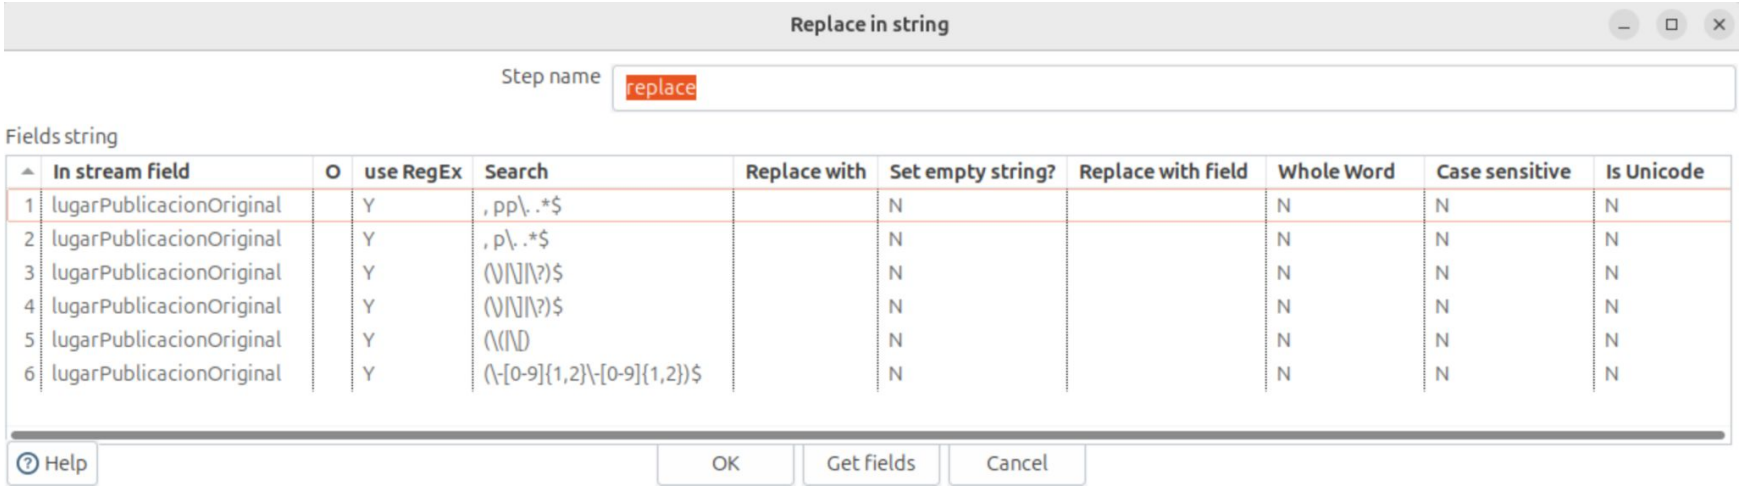

Expresiones regulares en PDI

String operations

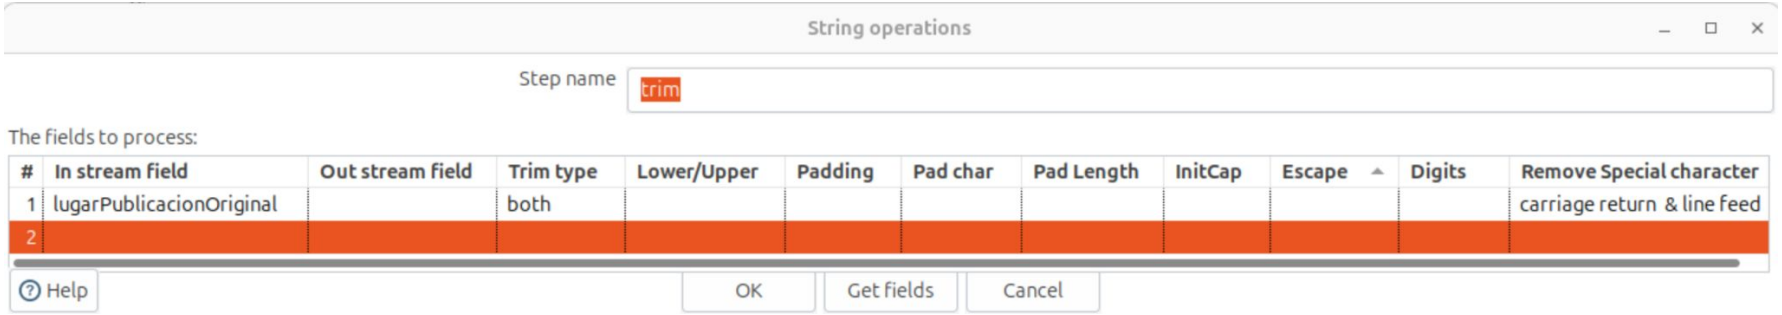

Expresiones regulares en PDI

Regex evaluation

Extraer fecha de publicación de la nota de mención original de una obra.

Debe estar en formato YYYY

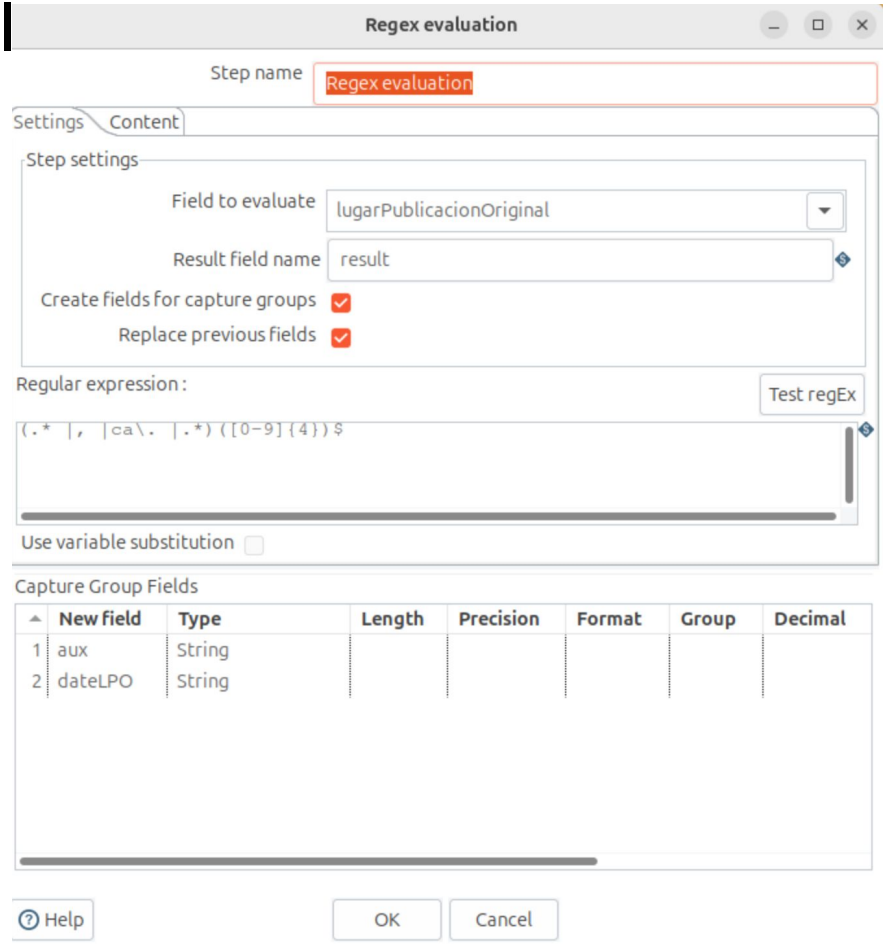

Expresiones regulares en PDI

Regex evaluation

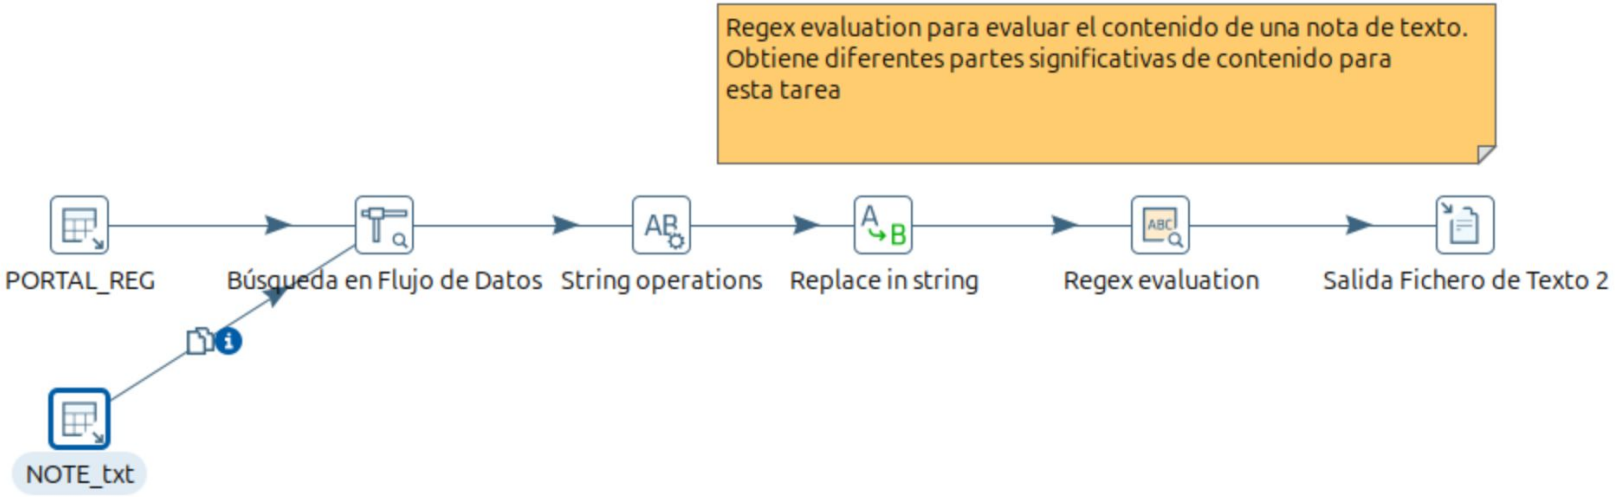

Expresiones regulares en PDI

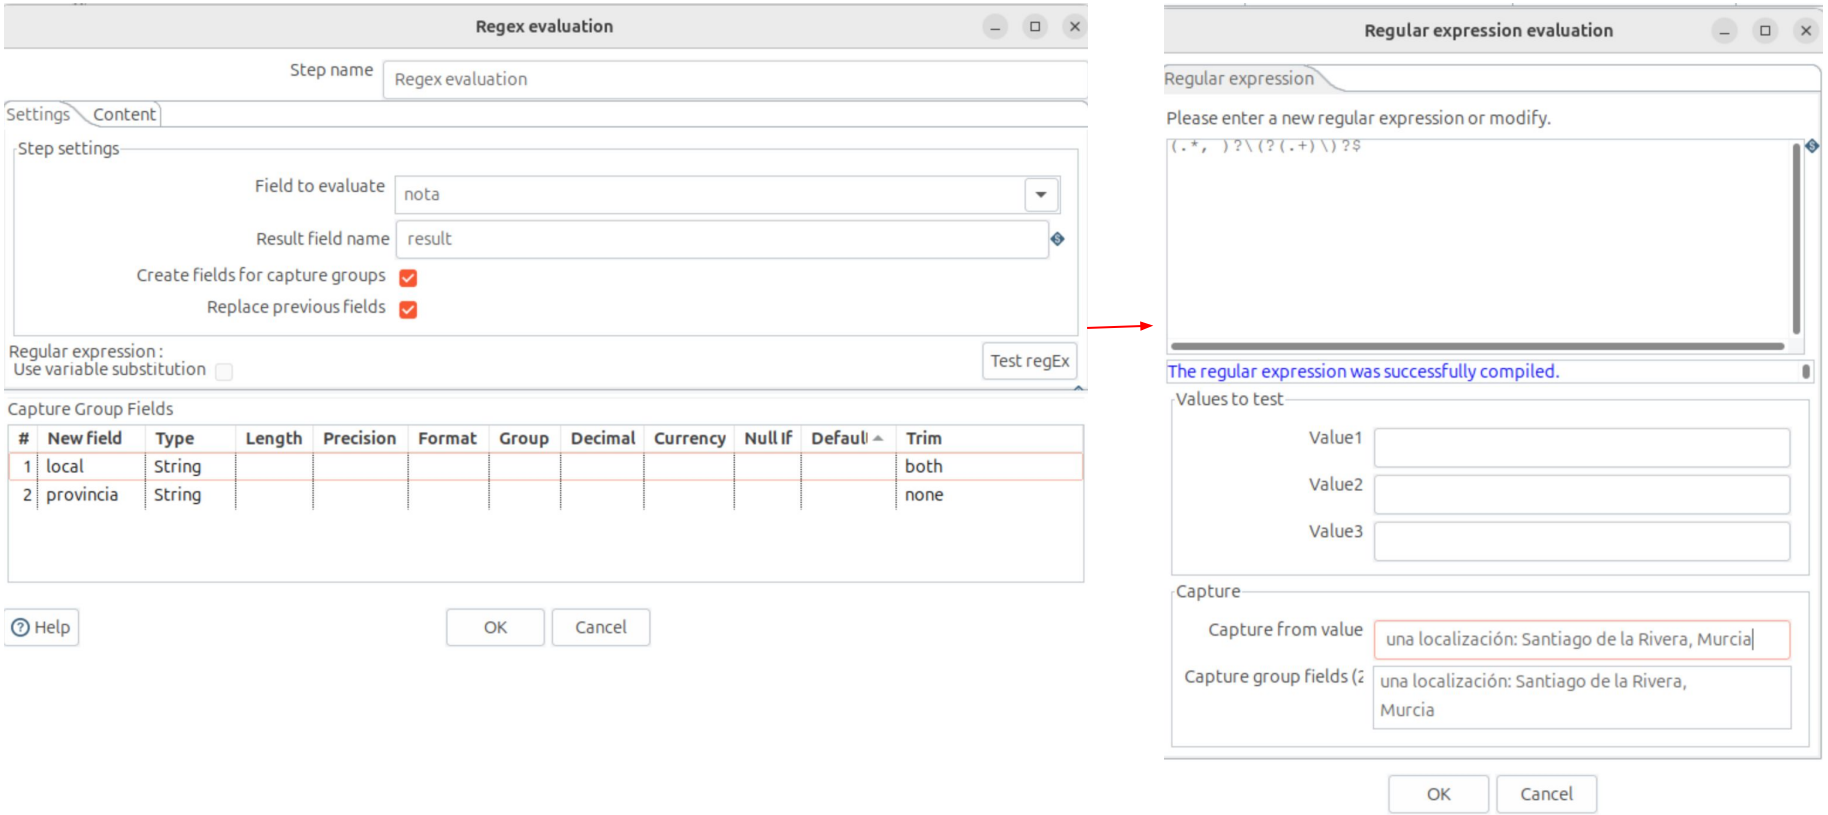

Expresiones regulares en PDI

(.*,)?\(?(.+)\)?$

notaOriginal	result	local	provincia
Auxiliar localización: Madrid	Y	<null>	Madrid
Auxiliar localización: Salnés, Pontevedra	Y	Salnés,	Pontevedra
Auxiliar localización: Albaicín, Granada	Y	Albaicín,	Granada
Auxiliar localización: Granada	Y	<null>	Granada
Auxiliar localización: Albaicín, Granada	Y	Albaicín,	Granada
Auxiliar localización: Albaicín, Granada	Y	Albaicín,	Granada
Auxiliar localización: Albaicín, Granada	Y	Albaicín,	Granada
Auxiliar localización: Granada	Y	<null>	Granada
Auxiliar localización: Granada	Y	<null>	Granada
Auxiliar localización: Granada	Y	<null>	Granada
Auxiliar localización: Granada	Y	<null>	Granada
Auxiliar localización: Granada	Y	<null>	Granada
Auxiliar localización: Motril, Granada	Y	Motril,	Granada
Auxiliar localización: Sanlúcar de Barrameda, Cádiz	Y	Sanlúcar de Barrameda,	Cádiz
Auxiliar localización: A Coruña	Y	<null>	A Coruña
Auxiliar localización: Toledo	Y	<null>	Toledo
Auxiliar localización: Jaén	Y	<null>	Jaén
Auxiliar localización: Córdoba	Y	<null>	Córdoba
Auxiliar localización: Palencia	Y	<null>	Palencia
Auxiliar localización: Tuñón, Asturias	Y	Tuñón,	Asturias
Auxiliar localización: Olot, Girona	Y	Olot,	Girona

Expresiones regulares en PDI

Funciones y operadores de expresiones regulares para Mysql

Name	Description
NOT REGEXP	Negation of REGEXP
REGEXP	Whether string matches regular expression
REGEXP_INSTR()	Starting index of substring matching regular expression
REGEXP_LIKE()	Whether string matches regular expression
REGEXP_REPLACE()	Replace substrings matching regular expression
REGEXP_SUBSTR()	Return substring matching regular expression
RLIKE	Whether string matches regular expression

Fuente: https://dev.mysql.com/doc/refman/8.4/en/regexp.html

Expresiones regulares en PDI

Uso REGEX de Mysql

```
SELECT

  idEntidadDocumental

, lugarPublicacionOriginal

, reproduccion

FROM MANIFESTACION m

WHERE reproduccion REGEXP '[Vv]ol\.(umen)?';
```

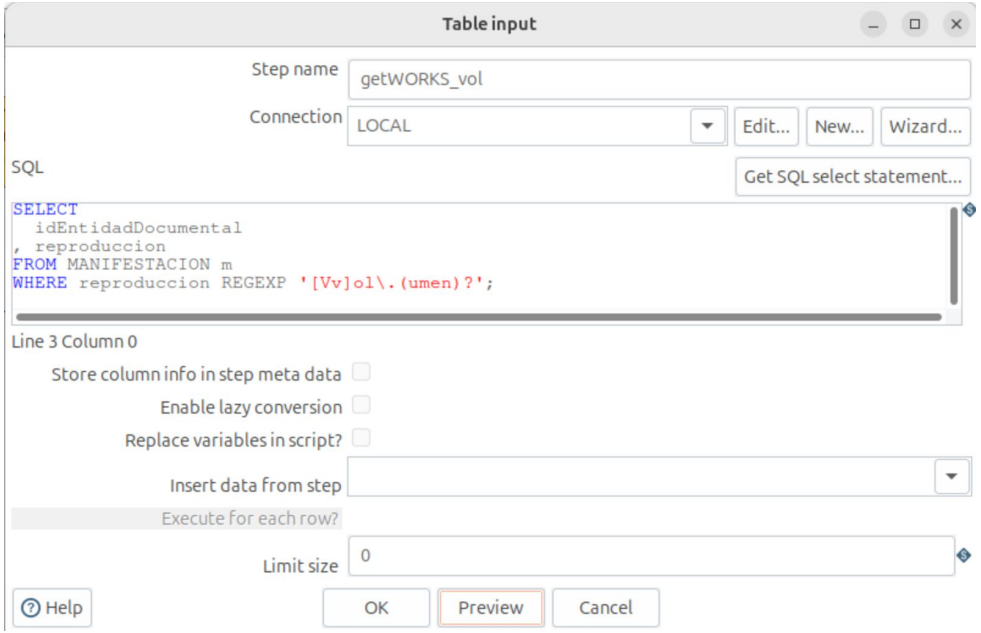

Expresiones regulares en PDI

Uso REGEX de Mysql

Resultado:

Edició digital basada en l' edició d'Alexandre Micha, Genève, Droz 1978-1983, **vols.**

Altra ed.: Catalan Review,**Volume** VI, numbers 1-2 (1992), pp. 393-399.

Otra ed.: Celestinesca,**vol.** 14, núm. 2 (nov. 1990), pp. 3-39

Edición digital a patir de la de Valencia, Herederos de Gerónimo Conejos, 1752, **vols.**

Altra ed.:Estudios Lulianos,**Vol.** 29 (1989), Fasc. 1, pp. 1-23. Fasc. 2, pp. 101-124

Expresiones regulares en PDI

JavaScript

Variante del ejercicio 2 - Validar una contraseña mediante una expresión regular. La contraseña debe tener entre 8 y 16 caracteres y contener al menos una letra minúscula, una mayúscula y un número.

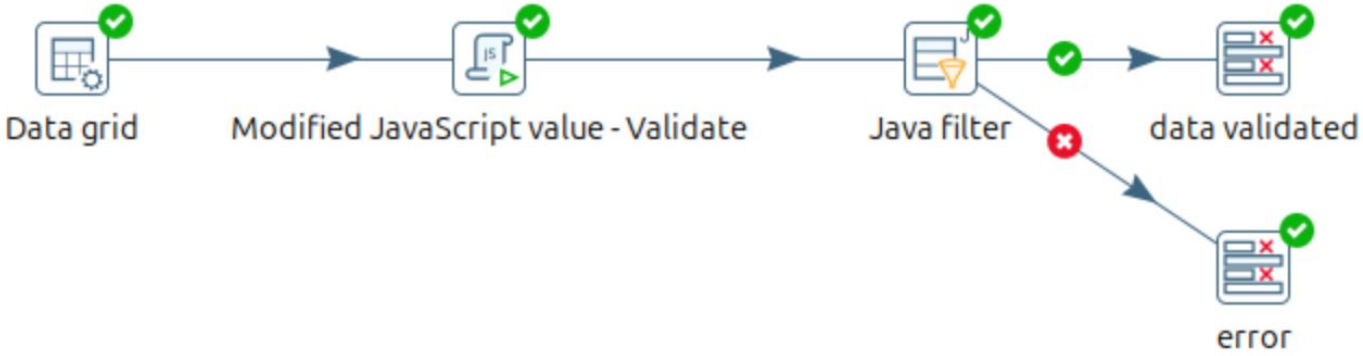

Expresiones regulares en PDI

Modified JavaScript value

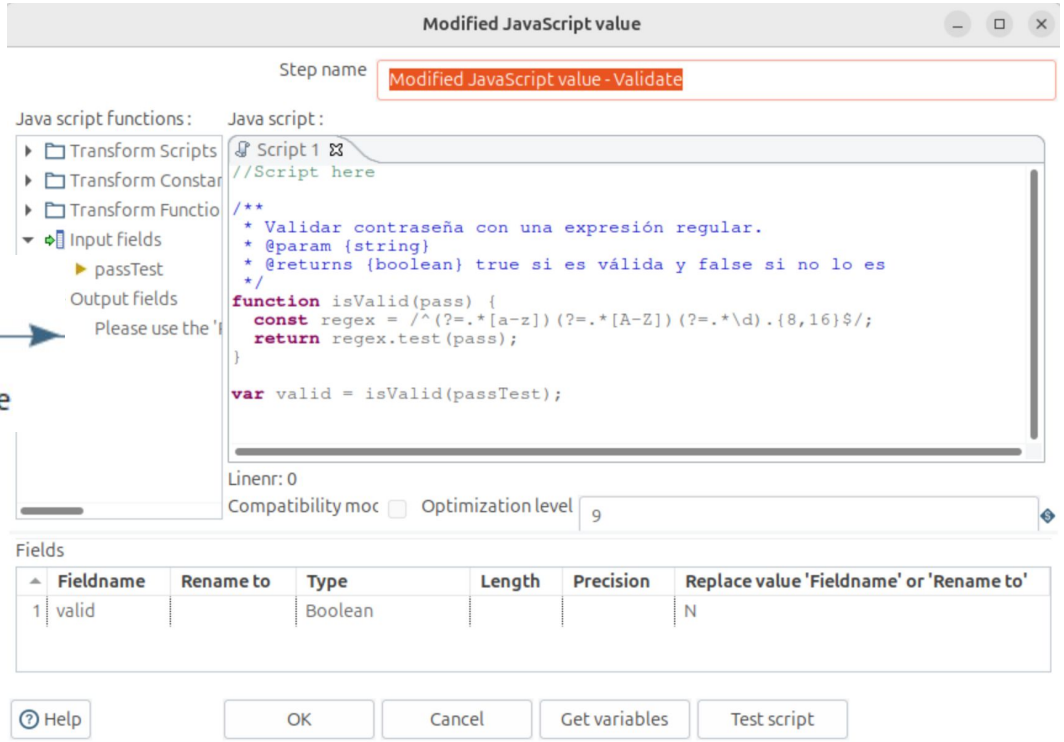

Expresiones regulares en PDI

Java filter

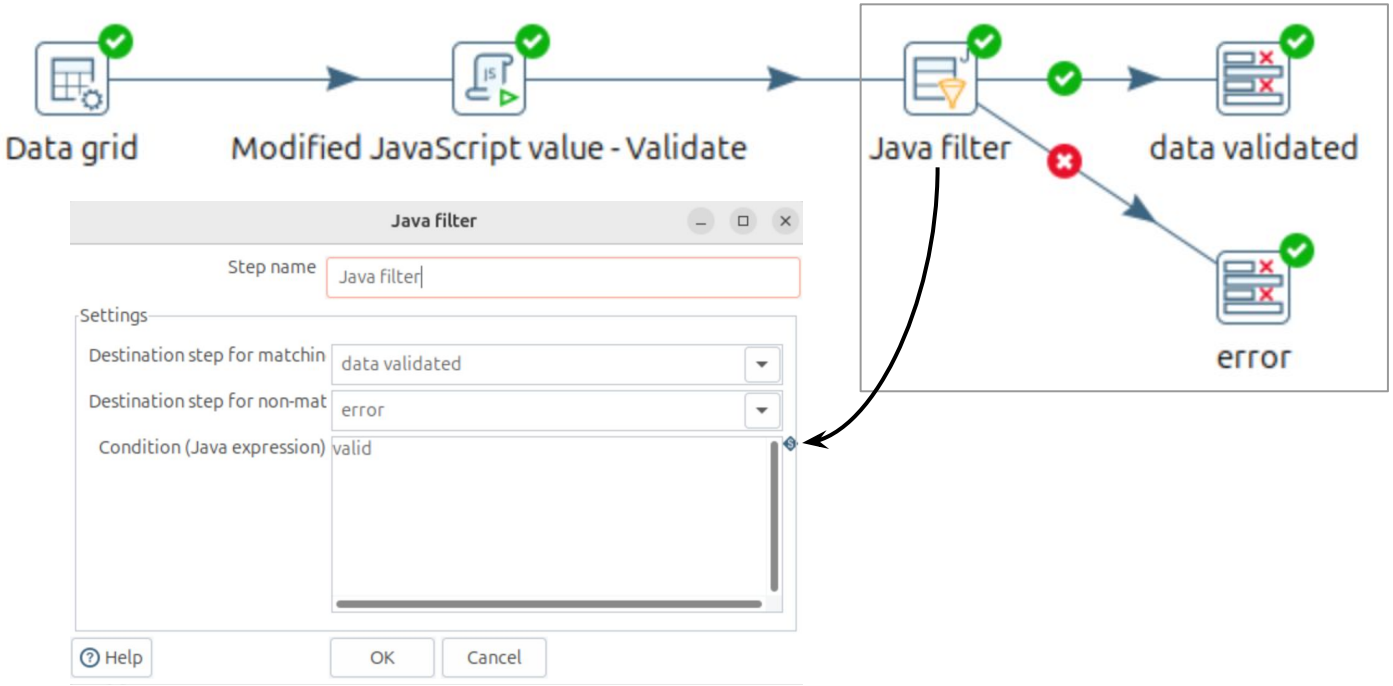

Referencias

- Kelhini, F. K. (2024). Text processing with JavaScript : regular expressions, tools, and techniques for optimal performance / (First edition.). The Pragmatic Programmers, LLC.
- MySQL 8.4 Reference Manual,Regular Expressions dev.mysql.com/doc/refman/8.4/en/regexp.html
- Learn SQL SQL Server learn.microsoft.com/es-es/sql/relational-databases/regular-expressions/overview?view=sql-server-ver17
- Pentaho Data Integration Regex Evaluation pentaho-public.atlassian.net/wiki/spaces/EAI/pages/371558254/Regex+Evaluation (earlier version)